6. Actividad Recursos K vecinos

November 4, 2026

[4]:
```
# Importamos las librerías necesarias para trabajar con KNN
# Cargamos la base de datos de Recursos Humanos

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

data = pd.read_csv("recursos_humanos.csv")

data
```

[4]:

	satisfaction_level	last_evaluation	number_project	\
0	0.38	0.53	2	
1	0.80	0.86	5	
2	0.11	0.88	7	
3	0.72	0.87	5	
4	0.37	0.52	2	
…	…	…	…	
14994	0.40	0.57	2	
14995	0.37	0.48	2	
14996	0.37	0.53	2	
14997	0.11	0.96	6	
14998	0.37	0.52	2	

	average_montly_hours	time_spend_company	Work_accident	left	\
0	157	3	0	1	
1	262	6	0	1	
2	272	4	0	1	
3	223	5	0	1	
4	159	3	0	1	
…	…	…	…	…	
14994	151	3	0	1	
14995	160	3	0	1	
14996	143	3	0	1	
14997	280	4	0	1	
14998	158	3	0	1	

```
       promotion_last_5years    sales  salary
0                          0    sales     low
1                          0    sales  medium
2                          0    sales  medium
3                          0    sales     low
4                          0    sales     low
…                        …      …      …
14994                      0  support     low
14995                      0  support     low
14996                      0  support     low
14997                      0  support     low
14998                      0  support     low

[14999 rows x 10 columns]
```

[3]:
```
# Mostramos los nombres de las columnas de nuestra base de datos

print(data.columns.tolist())
```

```
['satisfaction_level', 'last_evaluation', 'number_project',
'average_montly_hours', 'time_spend_company', 'Work_accident', 'left',
'promotion_last_5years', 'sales', 'salary']
```

[5]:
```
# Convertimos las variables categóricas sales y salary a variables numéricas
# Utilizamos pd.get_dummies para generar columnas con valores 0 y 1

data = pd.get_dummies(data, columns = ["sales", "salary"], dtype = int)

data.head()
```

[5]:
```
   satisfaction_level  last_evaluation  number_project  average_montly_hours  \
0                0.38             0.53               2                   157
1                0.80             0.86               5                   262
2                0.11             0.88               7                   272
3                0.72             0.87               5                   223
4                0.37             0.52               2                   159

   time_spend_company  Work_accident  left  promotion_last_5years  sales_IT  \
0                   3              0     1                      0         0
1                   6              0     1                      0         0
2                   4              0     1                      0         0
3                   5              0     1                      0         0
4                   3              0     1                      0         0

   sales_RandD  …  sales_hr  sales_management  sales_marketing  \
0            0  …         0                 0                0
1            0  …         0                 0                0
```

```
2            0  …         0                 0                 0
3            0  …         0                 0                 0
4            0  …         0                 0                 0

   sales_product_mng  sales_sales  sales_support  sales_technical  \
0                  0            1              0                0
1                  0            1              0                0
2                  0            1              0                0
3                  0            1              0                0
4                  0            1              0                0

   salary_high  salary_low  salary_medium
0            0           1              0
1            0           0              1
2            0           0              1
3            0           1              0
4            0           1              0

[5 rows x 21 columns]
```

[6]:
```
# Separamos la variable que queremos predecir
# y representa si el empleado dejó la empresa
# x_data contiene todas las variables predictoras

y = data.left.values

x_data = data.drop(["left"], axis = 1)
```

[7]:
```
# Mostramos los valores de la variable dependiente
# 0 = No dejó la empresa
# 1 = Sí dejó la empresa

y
```

[7]:
```
array([1, 1, 1, …, 1, 1, 1])
```

[8]:
```
# Mostramos las variables predictoras que utilizaremos en KNN

x_data
```

[8]:
```
       satisfaction_level  last_evaluation  number_project  \
0                    0.38             0.53               2
1                    0.80             0.86               5
2                    0.11             0.88               7
3                    0.72             0.87               5
4                    0.37             0.52               2
…                     …                …               …
```

```
14994                0.40             0.57                2
14995                0.37             0.48                2
14996                0.37             0.53                2
14997                0.11             0.96                6
14998                0.37             0.52                2

       average_montly_hours  time_spend_company  Work_accident  \
0                       157                   3              0
1                       262                   6              0
2                       272                   4              0
3                       223                   5              0
4                       159                   3              0
…                       …                     …              …
14994                   151                   3              0
14995                   160                   3              0
14996                   143                   3              0
14997                   280                   4              0
14998                   158                   3              0

       promotion_last_5years  sales_IT  sales_RandD  sales_accounting  \
0                          0         0            0                 0
1                          0         0            0                 0
2                          0         0            0                 0
3                          0         0            0                 0
4                          0         0            0                 0
…                          …         …            …                 …
14994                      0         0            0                 0
14995                      0         0            0                 0
14996                      0         0            0                 0
14997                      0         0            0                 0
14998                      0         0            0                 0

       sales_hr  sales_management  sales_marketing  sales_product_mng  \
0             0                 0                0                  0
1             0                 0                0                  0
2             0                 0                0                  0
3             0                 0                0                  0
4             0                 0                0                  0
…         …                 …                …                  …
14994         0                 0                0                  0
14995         0                 0                0                  0
14996         0                 0                0                  0
14997         0                 0                0                  0
14998         0                 0                0                  0

       sales_sales  sales_support  sales_technical  salary_high  salary_low  \
0                1              0                0            0           1
```

```
1                1              0               0           0           0
2                1              0               0           0           0
3                1              0               0           0           1
4                1              0               0           0           1
…              …              …               …           …           …
14994            0              1               0           0           1
14995            0              1               0           0           1
14996            0              1               0           0           1
14997            0              1               0           0           1
14998            0              1               0           0           1

       salary_medium
0                  0
1                  1
2                  1
3                  0
4                  0
…                …
14994              0
14995              0
14996              0
14997              0
14998              0

[14999 rows x 20 columns]
```

[9]:
```python
# Dividimos los datos en entrenamiento y prueba
# Utilizamos el 70% para entrenamiento y el 30% para prueba

from sklearn.model_selection import train_test_split

x_train, x_test, y_train, y_test = train_test_split(
    x_data, y, test_size = 0.30, random_state = 1
)
```

[13]:
```python
# Normalizamos las variables utilizando el método Min-Max
# Calculamos los valores mínimos y máximos por columna
# Utilizamos únicamente los datos de entrenamiento

minimos = x_train.min(axis=0)
maximos = x_train.max(axis=0)

rango = (maximos - minimos).replace(0, 1)

x_train = (x_train - minimos) / rango
x_test = (x_test - minimos) / rango
```

[14]:
```
# Contamos cuántos empleados dejaron la empresa y cuántos permanecieron

print(data["left"].value_counts())

# Calculamos los porcentajes de cada categoría
print(data["left"].value_counts(normalize=True) * 100)
```

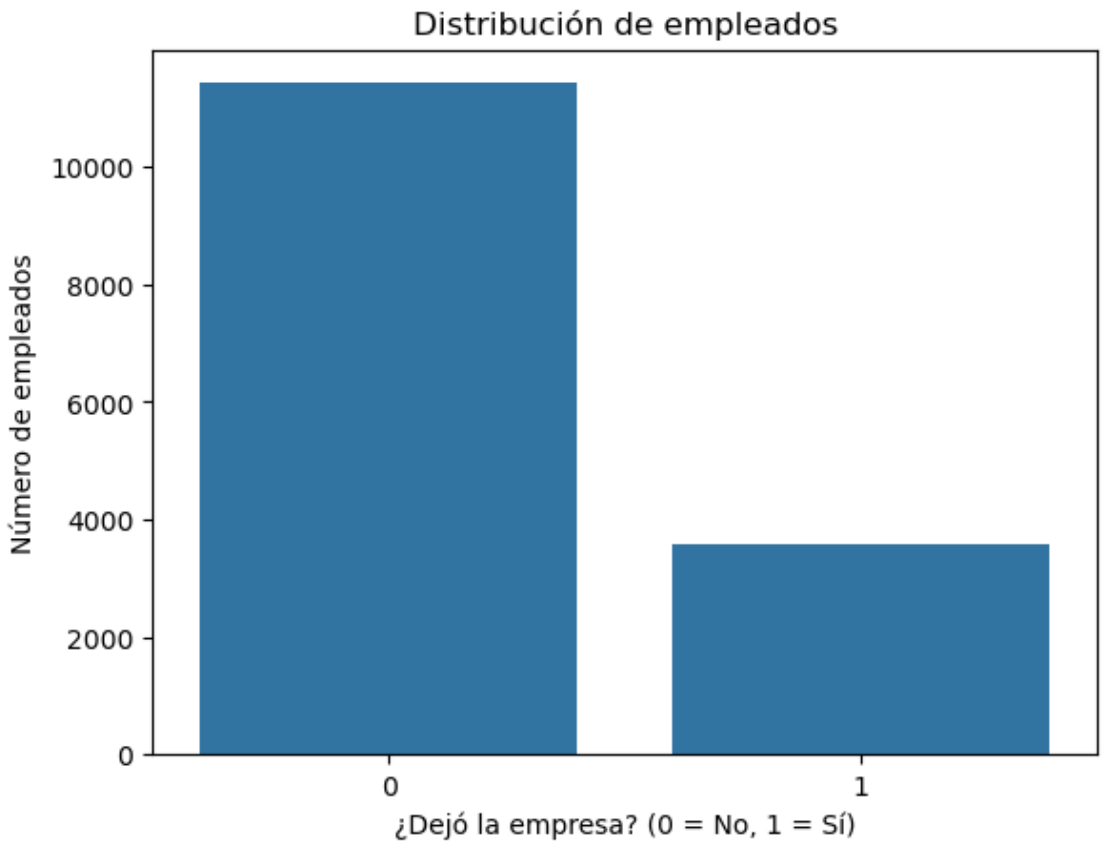
```
left
0    11428
1     3571
Name: count, dtype: int64
left
0    76.191746
1    23.808254
Name: proportion, dtype: float64
```

[15]:
```
# Graficamos la cantidad de empleados por categoría
# Comparamos quienes dejaron la empresa con quienes permanecieron

import seaborn as sns

sns.countplot(x = "left", data = data)

plt.title("Distribución de empleados")
plt.xlabel("¿Dejó la empresa? (0 = No, 1 = Sí)")
plt.ylabel("Número de empleados")
plt.show()
```



[16]:
```
# Aplicamos el algoritmo KNN utilizando inicialmente 3 vecinos
# Entrenamos el modelo y calculamos su precisión global

from sklearn.neighbors import KNeighborsClassifier

knn = KNeighborsClassifier(n_neighbors=3)

knn.fit(x_train, y_train)

prediction = knn.predict(x_test)

print("Score: ", knn.score(x_test, y_test))
```

```
/opt/conda/envs/anaconda-2025.12-py312/lib/python3.12/site-
packages/joblib/externals/loky/backend/context.py:131: UserWarning: Could not
find the number of physical cores for the following reason:
found 0 physical cores < 1
Returning the number of logical cores instead. You can silence this warning by
setting LOKY_MAX_CPU_COUNT to the number of cores you want to use.
  warnings.warn(
```

```
  File "/opt/conda/envs/anaconda-2025.12-py312/lib/python3.12/site-
packages/joblib/externals/loky/backend/context.py", line 255, in
_count_physical_cores
    raise ValueError(f"found {cpu_count_physical} physical cores < 1")
```

```
Score:  0.9453333333333334
```

[17]:
```python
# Evaluamos los valores de K desde 1 hasta 20
# Calculamos la precisión global y la precisión de cada categoría
# También calculamos recall, F1-score y AUC para comparar los modelos

from sklearn.metrics import confusion_matrix
from sklearn.metrics import precision_score
from sklearn.metrics import recall_score
from sklearn.metrics import f1_score
from sklearn.metrics import roc_auc_score

resultados = []

for k in range(1, 21):

    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(x_train, y_train)

    prediction = knn.predict(x_test)

    cm = confusion_matrix(y_test, prediction)

    PrecisionGlobal = knn.score(x_test, y_test)

    PrecisionNo = cm[0,0] / (cm[0,0] + cm[1,0])

    PrecisionSi = cm[1,1] / (cm[1,1] + cm[0,1])

    Recall = recall_score(y_test, prediction)

    F1 = f1_score(y_test, prediction)

    y_scores = knn.predict_proba(x_test)

    AUC = roc_auc_score(y_test, y_scores[:,1])

    resultados.append([
        k, PrecisionGlobal, PrecisionNo,
        PrecisionSi, Recall, F1, AUC
    ])
```

[18]:
```
# Convertimos los resultados a un DataFrame
# Mostramos las métricas para los 20 valores de K

tabla = pd.DataFrame(resultados, columns=[
    "K", "Precision Global", "Precision No",
    "Precision Si", "Recall", "F1", "AUC"
])

print(tabla.round(4).to_string(index=False))
```

```
 K  Precision Global  Precision No  Precision Si  Recall     F1    AUC
 1            0.9618        0.9845        0.8958  0.9520 0.9231 0.9585
 2            0.9578        0.9689        0.9217  0.9013 0.9114 0.9644
 3            0.9453        0.9751        0.8600  0.9234 0.8906 0.9660
 4            0.9460        0.9608        0.8978  0.8755 0.8865 0.9679
 5            0.9393        0.9621        0.8690  0.8810 0.8749 0.9666
 6            0.9447        0.9597        0.8957  0.8718 0.8836 0.9664
 7            0.9411        0.9603        0.8802  0.8745 0.8774 0.9662
 8            0.9393        0.9554        0.8866  0.8579 0.8720 0.9649
 9            0.9324        0.9560        0.8585  0.8616 0.8600 0.9633
10            0.9340        0.9535        0.8709  0.8524 0.8615 0.9625
11            0.9293        0.9540        0.8520  0.8552 0.8536 0.9623
12            0.9311        0.9538        0.8590  0.8542 0.8566 0.9617
13            0.9262        0.9538        0.8412  0.8552 0.8481 0.9598
14            0.9289        0.9537        0.8511  0.8542 0.8527 0.9593
15            0.9253        0.9537        0.8382  0.8552 0.8466 0.9583
16            0.9264        0.9496        0.8522  0.8404 0.8463 0.9570
17            0.9229        0.9501        0.8378  0.8432 0.8405 0.9556
18            0.9211        0.9450        0.8435  0.8256 0.8345 0.9539
19            0.9187        0.9449        0.8349  0.8256 0.8302 0.9526
20            0.9189        0.9433        0.8395  0.8201 0.8297 0.9515
```

[19]:
```
# Graficamos las precisiones de los distintos valores de K
# Comparamos la precisión global y las dos precisiones por categoría

plt.figure(figsize=(10,6))

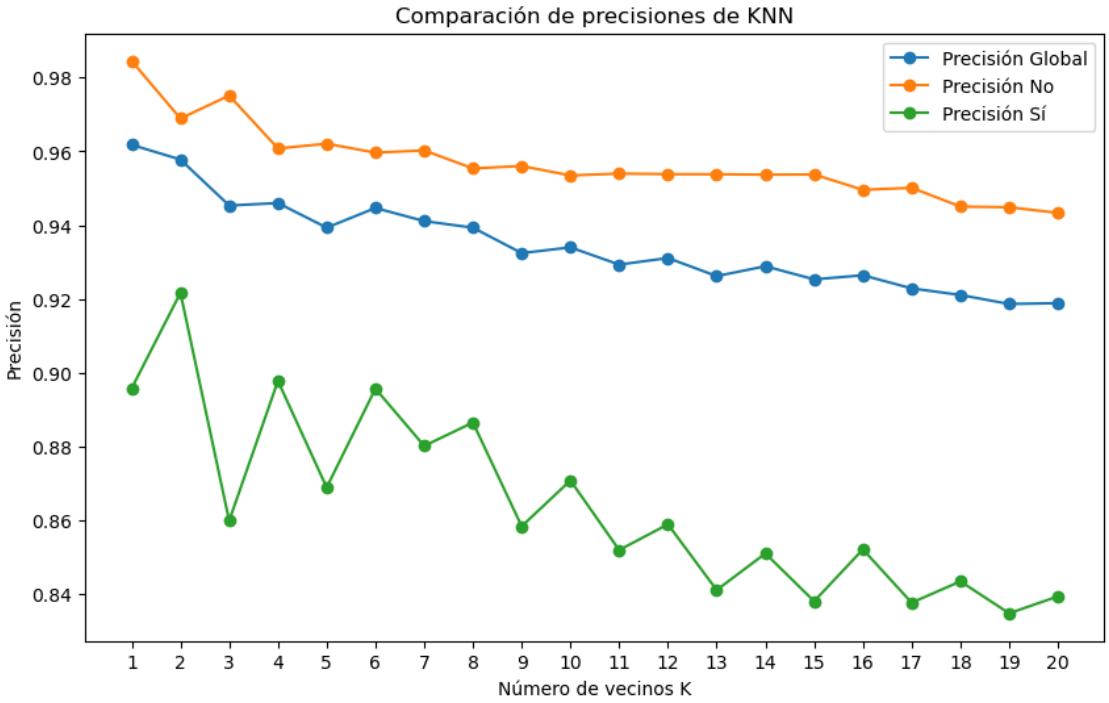
plt.plot(tabla["K"], tabla["Precision Global"],
         label="Precisión Global", marker="o")

plt.plot(tabla["K"], tabla["Precision No"],
         label="Precisión No", marker="o")

plt.plot(tabla["K"], tabla["Precision Si"],
         label="Precisión Sí", marker="o")

plt.xlabel("Número de vecinos K")
```

```
plt.ylabel("Precisión")
plt.title("Comparación de precisiones de KNN")
plt.xticks(range(1,21))
plt.legend()
plt.show()
```



[20]:
```
# Identificamos el K que obtuvo la mayor precisión global
# Mostramos sus resultados para justificar la elección

mejor_k = tabla.loc[tabla["Precision Global"].idxmax(), "K"]

print("Valor óptimo de K:", mejor_k)

print(tabla[tabla["K"] == mejor_k])
```

```
Valor óptimo de K: 1
   K  Precision Global  Precision No  Precision Si    Recall        F1       AUC
0  1          0.961778      0.984468      0.895833  0.95203  0.923077  0.95845
```

[21]:
```
# Entrenamos el modelo definitivo utilizando el K óptimo
# Realizamos las predicciones para evaluar el modelo

knn = KNeighborsClassifier(n_neighbors=int(mejor_k))
```

```
knn.fit(x_train, y_train)

prediction = knn.predict(x_test)

print("Score: ", knn.score(x_test, y_test))
```

```
Score:  0.9617777777777777
```

[22]:
```
# Guardamos los valores pronosticados y los valores reales
# Los utilizaremos para calcular la matriz de confusión

y_pred = prediction

y_true = y_test
```

[23]:
```
# Calculamos la matriz de confusión del modelo KNN
# Comparamos las predicciones con los valores reales

from sklearn.metrics import confusion_matrix

cm = confusion_matrix(y_true, y_pred)

cm
```

[23]:
```
array([[3296,  120],
       [  52, 1032]])
```

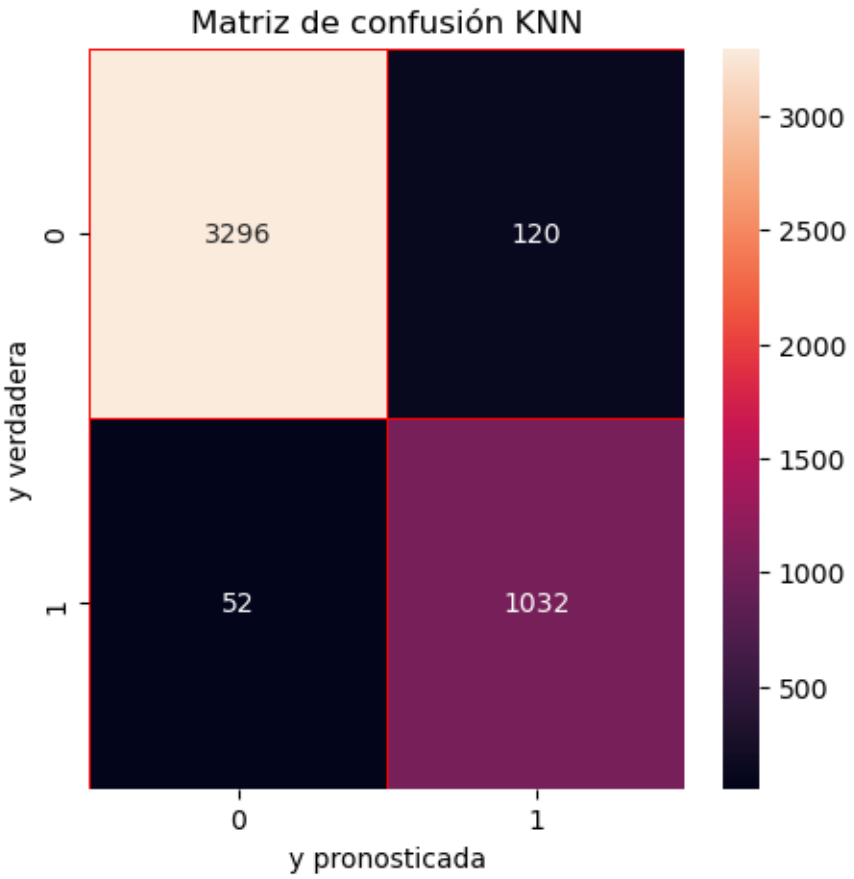
[24]:
```
# Graficamos el mapa de calor de la matriz de confusión
# Mostramos los aciertos y errores del modelo

import seaborn as sns

f, ax = plt.subplots(figsize = (5,5))

sns.heatmap(cm, annot = True, linewidths = 0.5,
            linecolor = "red", fmt = ".0f", ax = ax)

plt.xlabel("y pronosticada")
plt.ylabel("y verdadera")
plt.title("Matriz de confusión KNN")
plt.show()
```



[25]:
```
# Calculamos la cantidad de predicciones correctas e incorrectas
# Obtenemos la precisión global mediante la matriz de confusión

Correctos = cm[0,0] + cm[1,1]

Incorrectos = cm[0,1] + cm[1,0]

PrecisionGlobal = Correctos / (Correctos + Incorrectos)

print("Precisión Global:", PrecisionGlobal)
```

```
Precisión Global: 0.9617777777777777
```

[26]:
```
# Calculamos la precisión de la categoría 0
# Empleados que no dejaron la empresa

PrecisionNo = cm[0,0] / (cm[0,0] + cm[1,0])

print("Precisión No:", PrecisionNo)
```

```
Precisión No: 0.984468339307049
```

[27]:
```
# Calculamos la precisión de la categoría 1
# Empleados que sí dejaron la empresa

PrecisionSi = cm[1,1] / (cm[1,1] + cm[0,1])

print("Precisión Sí:", PrecisionSi)
```

```
Precisión Sí: 0.8958333333333334
```

[28]:
```
# Importamos las funciones para calcular la curva ROC
# y el área bajo la curva AUC

from sklearn.metrics import roc_curve
from sklearn.metrics import auc
```

[29]:
```
# Calculamos las probabilidades pronosticadas por el modelo KNN
# Utilizamos el modelo con K óptimo

y_scores = knn.predict_proba(x_test)

print(y_scores)
```

```
[[1. 0.]
 [1. 0.]
 [1. 0.]
 …
 [1. 0.]
 [1. 0.]
 [0. 1.]]
```

[30]:
```
# Calculamos la curva ROC y el área bajo la curva
# Evaluamos la capacidad del modelo para identificar empleados
# que abandonaron la empresa

fpr, tpr, threshold = roc_curve(y_test, y_scores[:,1])

# fpr = False positive rate, tpr = True positive rate
roc_auc = auc(fpr, tpr)

plt.title('Receiver Operating Characteristic')

plt.plot(fpr, tpr, 'b', label = 'AUC = %0.2f' % roc_auc)

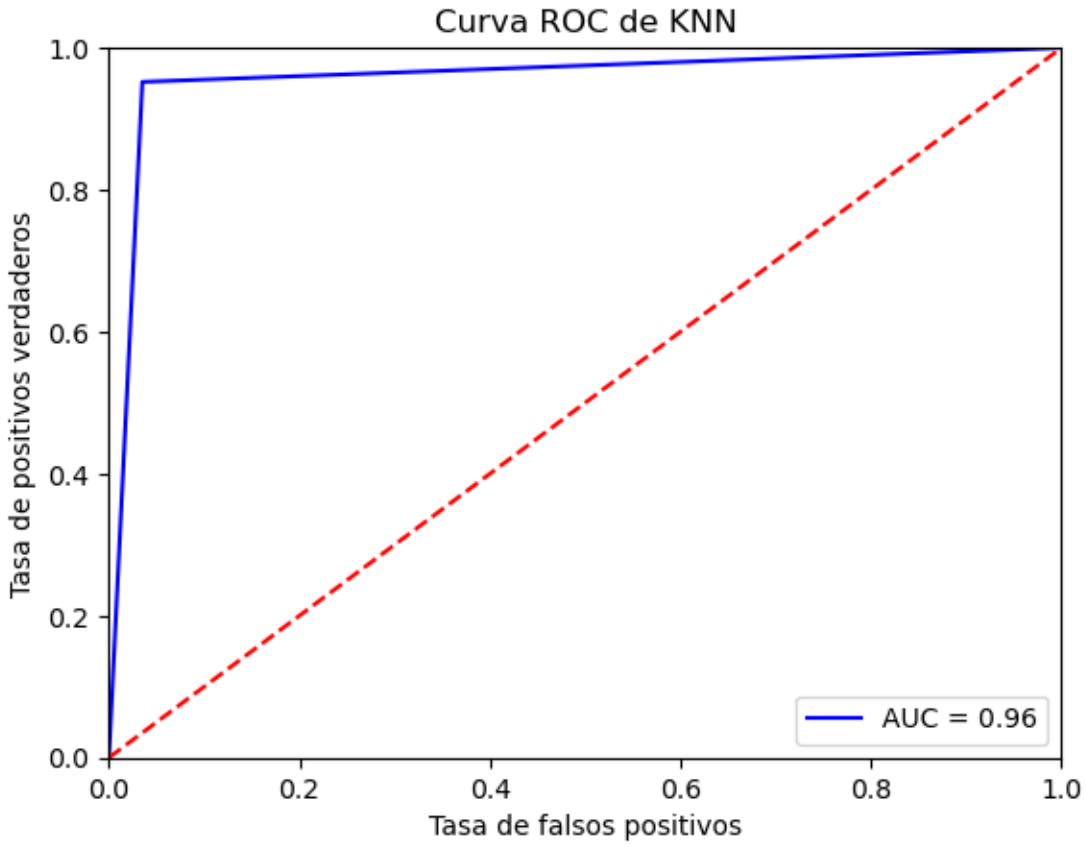
plt.legend(loc = 'lower right')

plt.plot([0,1], [0,1], 'r--')
```

```
plt.xlim([0,1])
plt.ylim([0,1])

plt.ylabel("Tasa de positivos verdaderos")
plt.xlabel("Tasa de falsos positivos")

plt.title("Curva ROC de KNN")
plt.show()
```



[ ]: