

Introducción al Análisis de Componentes Principales (PCA)

Daniel Alejandro Lopez Mendez

Para comenzar tenemos que poner la base de datos en un pd , con el siguiente código

```
df = pd.read_csv("iris.csv")
df
```

	sepal.length	sepal.width	petal.length	petal.width	variety
0	5.1	3.5	1.4	0.2	Setosa
1	4.9	3.0	1.4	0.2	Setosa
2	4.7	3.2	1.3	0.2	Setosa
3	4.6	3.1	1.5	0.2	Setosa
4	5.0	3.6	1.4	0.2	Setosa
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	Virginica
146	6.3	2.5	5.0	1.9	Virginica
147	6.5	3.0	5.2	2.0	Virginica
148	6.2	3.4	5.4	2.3	Virginica
149	5.9	3.0	5.1	1.8	Virginica

150 rows × 5 columns

A continuación estandarizamos la base de datos a excepción de la última variable que contiene caracteres

```
# Estandarización de Las variables
df2 = StandardScaler().fit_transform(df[['sepal.length', 'sepal.width', 'petal.length', 'petal.width']])
df2
```

```
# Calcular la matriz de correlaciones para la matriz transformada
renglones = df2.shape[0]
A = (1/renglones) * np.dot(df2.T, df2)
A
```

```

|: # Entrenamiento del modelo PCA con escalado de los datos
pca_pipe = make_pipeline(StandardScaler(), PCA())
pca_pipe.fit(df[['sepal.length', 'sepal.width', 'petal.length', 'petal.width']])

# Se extrae el modelo entrenado del pipeline
modelo_pca = pca_pipe.named_steps['pca']

print("Eigenvalores:")
results = LA.eigvals(A)
print(results)

```

```

Eigenvalores:
[2.91849782 0.91403047 0.14675688 0.02071484]

```

```

# Porcentaje de la varianza explicada por cada nuevo componente
print("Porcentaje de varianza explicada por componente")
print(modelo_pca.explained_variance_ratio_)

```

```

Porcentaje de varianza explicada por componente
[0.72962445 0.22850762 0.03668922 0.00517871]

```

```

# Cálculo de eigenvectores
print("Eigenvectores (por renglon):")
pd.DataFrame(data = modelo_pca.components_,
              columns = ['sepal.length', 'sepal.width', 'petal.length', 'petal.width'],
              index = ['PC1', 'PC2', 'PC3', 'PC4'])

```

Eigenvectores (por renglon):

	sepal.length	sepal.width	petal.length	petal.width
PC1	0.521066	-0.269347	0.580413	0.564857
PC2	0.377418	0.923296	0.024492	0.066942
PC3	-0.719566	0.244382	0.142126	0.634273
PC4	-0.261286	0.123510	0.801449	-0.523597

```

# Proyecciones de los componentes
proyecciones = np.dot(modelo_pca.components_, df2.T)
proyecciones = pd.DataFrame(proyecciones, index = ['PC1', 'PC2', 'PC3', 'PC4'])
proyecciones = proyecciones.transpose().set_index(df.index)
proyecciones

```

2) Grado de explicacion de la varianza

Porcentaje de varianza
[0.72962445 0.22850762]

95.813% de varianza explicado por los primeros 2 componentes

```



x = proyecciones.iloc[:,0]
y = proyecciones.iloc[:,1]
z = df['variety']
x = x.to_numpy()
y = y.to_numpy()

fig, ax = plt.subplots()
ax.set_title("Mapa de observaciones")
ax.scatter(x,y)

for i, txt in enumerate(z):
    ax.annotate(txt, (x[i], y[i]))

```

3)



Al comparar los 2 mapas podemos ver que si están distribuidas en 2 grupos bien delimitados, 2 clusters bien definidos, petal length y width van de la mano, un poco pegado con sepal length y al lado opuesto total esta sepal width

en el mapa de observaciones las flores setosa aparece muy separada del grupo que justo es a donde se va la parte de sepal width, así que las setosas se diferencian de las demás por su sepal width